

Inteligencia Artificial

Apuntes de la clase 07/08/2025

Fernando Daniel Brenes Reyes
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
Cartago, Costa Rica
2020097446@estudiantec.cr

Abstract—Estos apuntes organizan y amplían el material introductorio de la clase sobre Inteligencia Artificial. Se incluyen noticias recientes, fundamentos técnicos, cuestiones prácticas, una línea de tiempo histórica, y una descripción de las principales ramas del aprendizaje automático. El documento está preparado en formato IEEE, con lugares marcados para figuras y sugerencias bibliográficas.

Index Terms—Inteligencia Artificial, GPT-5, Autos Autónomos, Datos, Aprendizaje Supervisado, Aprendizaje No Supervisado.

I. INTRODUCCIÓN

La Inteligencia Artificial (IA) es un campo multidisciplinario que combina informática, estadística, matemática y aspectos del dominio de aplicación para crear sistemas que pueden percibir, razonar, aprender y actuar. En esta compilación ampliada se cubren conceptos teóricos, avances recientes y aplicaciones prácticas relevantes para un curso introductorio.

II. NOTICIAS Y CONTEXTO RECIENTE

A. GPT-5 y modelos de lenguaje avanzados

A mediados de 2025 emergieron nuevas generaciones de grandes modelos de lenguaje con capacidades multimodales, mejor manejo del contexto y mejoras en razonamiento. Estos modelos impactan fuertemente en herramientas de productividad (resúmenes, generación de código, asistencia de escritura) y han generado debate acerca de su adopción responsable y efectos laborales.

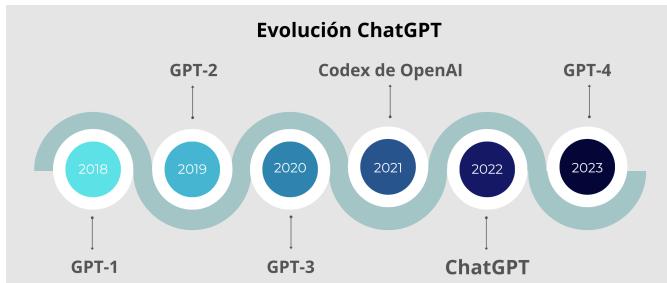


Fig. 1. Línea simplificada de evolución de modelos de lenguaje: GPT-1 → GPT-2 → GPT-3 → GPT-4

B. Impacto en el empleo y en programadores

La automatización con IA está permitiendo a organizaciones reducir tiempo en tareas repetitivas (redacción de correos, generación de reportes, tests básicos de software). Para programadores esto significa:

- **Aumento de productividad:** asistentes que generan esqueleto de código y pruebas unitarias.
- **Cambio en habilidades requeridas:** mayor énfasis en diseño, validación, ética, pruebas adversariales y orquestación.
- **Riesgos:** tareas de bajo nivel y rutinas repetitivas pueden verse desplazadas; se recomienda desarrollar habilidades de alto valor (arquitectura, ingeniería de datos, DevOps, ML Ops).

C. Autos autónomos en California

California es uno de los centros donde empresas realizan pruebas y despliegues de vehículos autónomos; estos sistemas integran LIDAR, cámaras, mapas HD y planificación en tiempo real. Las áreas de interés incluyen:

- **Sensores y fusión:** LIDAR + cámaras + radar + GPS.
- **Percepción:** detección y clasificación de peatones, vehículos y señales.
- **Planificación:** toma de decisiones en entornos urbanos complejos.
- **Protocolos de emergencia:** procedimientos para fallas del sistema, intervención humana y registro de eventos.



Fig. 2. Vehículo autónomo: sensores, percepción, planificación y control.

III. DEFINICIONES Y CONCEPTOS BÁSICOS

A. ¿Qué es inteligencia?

No existe una definición única aceptada. En IA operativa se suele entender como la *capacidad de un sistema para percibir su entorno, razonar, tomar decisiones autónomas y adaptarse a cambios*. Distintos campos (psicología, filosofía, ciencias de la computación) aportan matices: aprendizaje, simbolismo, razonamiento probabilístico, entre otros.

B. Autónomo vs. adaptativo

Autónomo: actúa sin intervención humana constante.

Adaptativo: modifica su comportamiento basándose en nueva información o retroalimentación.

Un sistema puede ser autónomo pero no adaptativo (p. ej. un robot con una ruta fija) o adaptativo pero no completamente autónomo (p. ej. un asistente que sugiere cambios que un humano valida).

C. Capacidad de generalización

La generalización es la habilidad de un modelo de desempeñarse bien sobre datos no vistos durante el entrenamiento. Es el objetivo central al medir la utilidad práctica de un modelo.

IV. DEEP LEARNING Y REDES NEURONALES

A. Perceptrón y orígenes

El perceptrón (década de 1950) es un modelo de unidad de decisión lineal que calcula una combinación ponderada de entradas y aplica una función de activación. Funciona bien para problemas linealmente separables, pero no puede resolver problemas no lineales (ej. XOR).

B. Redes profundas y arquitecturas comunes

El deep learning usa redes con muchas capas: perceptrones multicapa (MLP), redes convolucionales (CNN) y redes recurrentes (RNN/LSTM/Transformer). Cada arquitectura está orientada a distintos tipos de datos:

- **CNN:** imágenes y datos con estructura espacial.
- **RNN / LSTM:** secuencias temporales y texto (históricamente).
- **Transformers:** atención y modelado de dependencias a larga distancia (estado del arte en NLU y NLG).

C. Yann LeCun y las CNN

Yann LeCun fue pionero en redes convolucionales (LeNet) y en su aplicación al reconocimiento de dígitos. Las CNN aprenden filtros que detectan características locales (bordes, texturas) y luego construyen representaciones de alto nivel mediante capas sucesivas.

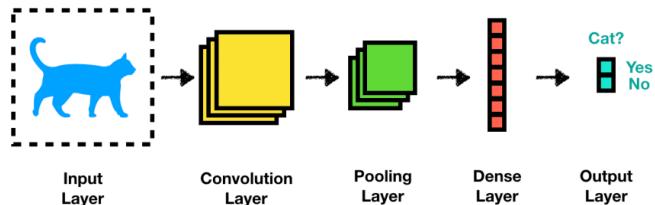


Fig. 3. Esquema de una red convolucional

V. DATOS: EL CORAZÓN DE LA IA

A. Calidad y preprocessamiento

Los datos deben ser:

- **Representativos** del problema real.
- **Limpios:** sin errores obvios (p. ej. mezcla Celsius/Fahrenheit).
- **Balanceados** o bien tratados para evitar sesgos.
- **Steven Pacheco 2025** - Si tenemos mal los datos, mala es la salida de nuestra función

Técnicas comunes: normalización, imputación (media/mediana), detección y tratamiento de outliers, ingeniería de características y enriquecimiento.

B. Sesgos y equidad

Los datasets reflejan las desigualdades del mundo real. Un modelo entrenado con datos sesgados puede perpetuar discriminaciones. Ejemplos prácticos:

- Reconocimiento facial con peor desempeño en ciertos grupos demográficos.
- Modelos de crédito que penalizan poblaciones subrepresentadas.

Buenas prácticas: auditorías de sesgo, conjuntos de prueba estratificados, transparencia en datos y procesos.

C. Ejemplo del profe: Celsius vs Fahrenheit

Un error clásico en datasets es mezclar unidades. Si un campo de temperatura contiene valores en ambas escalas sin etiqueta, el modelo puede aprender patrones erróneos. Es esencial normalizar unidades y validar rangos.

VI. BREVE HISTORIA DE LA IA (LÍNEA DEL TIEMPO)

- **1950s:** Perceptrón y primeras investigaciones (Rosenblatt).
- **1960s:** Nacimiento temprano del Machine Learning y primeros sistemas simbólicos.
- **1970s:** Lenguajes lógicos (Prolog), algoritmos clásicos (Dijkstra).
- **1980s:** Inicio de la experimentación con autos autónomos.
- **1990s:** Resurgimiento con redes multicapa y aprendizaje por refuerzo.
- **2000s:** Auge del reconocimiento facial y visión por computadora.
- **2010s–2020s:** Deep learning, grandes modelos de lenguaje, despliegues comerciales.

VII. RAMAS DEL APRENDIZAJE AUTOMÁTICO

A. Aprendizaje Supervisado

Consiste en aprender una función $f : X \rightarrow Y$ a partir de ejemplos etiquetados (x_i, y_i) . Técnicas: regresión lineal, SVM, árboles, redes neuronales. Se evalúa con métricas como RMSE, accuracy, F1.

B. Aprendizaje No Supervisado

No hay etiquetas; el objetivo es encontrar estructura. Técnicas: clustering (k-means, DBSCAN), reducción de dimensionalidad (PCA, t-SNE, UMAP).

C. Aprendizaje por Refuerzo

Agentes aprenden interactuando con un entorno y recibiendo recompensas. Aplicaciones: juegos (Atari, Go), control robótico. Referencia clásica: Sutton & Barto.



Fig. 4. Ejemplo de aprendizaje por refuerzo

VIII. CIENTÍFICO VS INGENIERO EN IA

Científico de IA: foco en investigación, nuevos modelos, experimentos.

Ingeniero de IA / ML Engineer: foco en producción, rendimiento, escalabilidad, MLOps y despliegue.

Ambos roles se complementan; en proyectos reales conviven y colaboran.

IX. TIPOS DE APRENDIZAJE EN IA

A. Aprendizaje Supervisado

- **Definición:** Modelo que aprende a partir de datos etiquetados (características + valores conocidos).

- **Ejemplo:** Predecir el precio de una casa usando sus características.

- **Proceso:**

- División: Muestra (características) + Etiqueta (valor objetivo).
- Aproximación: Minimiza el error mediante una **función de pérdida (L)**.

- **Técnicas:**

- Regresión (valores continuos).
- Clasificación (categorías discretas).

B. Aprendizaje No Supervisado

- **Definición:** Modelo identifica patrones en datos **sin etiquetas**.
- **Ejemplo:** Agrupamiento de clientes por hábitos de compra.
- **Técnicas:**
 - Clustering (ej. K-means).
 - Reducción de dimensionalidad (ej. PCA).

C. Comparación

Aspecto	Supervisado	No Supervisado
Datos	Etiquetados	Sin etiquetas
Objetivo	Predicción	Descubrir patrones
Ejemplos	Regresión, Clasificación	Clustering



Fig. 5. Ejemplo de aprendizaje por refuerzo

CONCLUSIÓN

La IA es un campo en rápida evolución: combina teoría matemática, ingeniería de software y consideraciones éticas. Comprender fundamentos, cuidar la calidad de los datos y adquirir habilidades prácticas (Keras, MLOps, validación) son claves para trabajar efectivamente en este ámbito.