

Apuntes semana 5 Clase #1s

Eder Vega Suazo
Escuela de Ingeniería en Computación
Instituto Tecnológico de Costa Rica
IC-6200 - Inteligencia Artificial Gr2

Resumen—Este documento es un resumen de la clase de inteligencia artificial correspondiente a la semana 5, enfocando en los fundamentos del aprendizaje supervisado. Se abordan temas clave como la optimización de modelos mediante cálculo diferencial y el algoritmo de descenso de gradiente aplicado a la función de error cuadrático medio. Además, se examinan desafíos comunes en el modelado predictivo, incluyendo el manejo de relaciones no lineales entre variables y la detección de valores atípicos. También discuten estrategias para la evaluación de modelos mediante partición de datasets y se analiza el compromiso entre sesgo y varianza, crucial para desarrollar modelos con capacidad de generalización efectiva.

I. OPTIMIZACIÓN MEDIANTE CÁLCULO DIFERENCIAL

I-A. Función de error cuadrático medio

En problemas de regresión, la función de costo más común está dada por:

$$L = \frac{1}{N} \sum_{i=1}^N (f_{w,b}(x_i) - y_i)^2, \quad i = 1, \dots, N$$

donde $h_\theta(x_i)$ representa la predicción del modelo para la instancia i -ésima.

El proceso de optimización busca minimizar esta función mediante el cálculo de gradientes:

$$\begin{aligned} \frac{\partial L}{\partial w} &= \frac{1}{N} \sum_{i=1}^N 2((wx_i + b) - y_i) \cdot x_i \\ \frac{\partial L}{\partial b} &= \frac{1}{N} \sum_{i=1}^N 2((wx_i + b) - y_i) \end{aligned}$$

I-B. Algoritmo de descenso de gradiente

La actualización de parámetros se realiza de forma iterativa mediante:

$$\begin{aligned} w^{(t+1)} &= w^{(t)} - \alpha \frac{\partial L}{\partial w^{(t)}} \\ b^{(t+1)} &= b^{(t)} - \alpha \frac{\partial L}{\partial b^{(t)}} \end{aligned}$$

donde α representa la tasa de aprendizaje que controla la magnitud de cada actualización.

I-C. Terminología fundamental

- **Época (Epoch)**: Ciclo completo de presentación de todos los ejemplos de entrenamiento al modelo.
- **Lote (Batch)**: Subconjunto de ejemplos utilizados para calcular una actualización de parámetros.
- **Tasa de aprendizaje**: Hyperparámetro que determina la velocidad de convergencia del algoritmo.

II. DESAFÍOS EN MODELADO PREDICTIVO

II-A. Relaciones no lineales entre variables

La regresión lineal presume una relación lineal entre predictores y variable respuesta. Cuando esta suposición se viola, el modelo resulta inadecuado y muestra patrones sistemáticos en los residuos:

$$e_i = y_i - \hat{y}_i$$

La solución implica transformar las variables predictoras mediante expansión polinomial o otras transformaciones que permitan capturar relaciones no lineales manteniendo la linealidad en los parámetros.




Figura 1: Ejemplo de relación no lineal y su ajuste mediante transformación polinomial.

II-B. Manejo de valores atípicos

Las observaciones extremas pueden distorsionar significativamente los modelos de regresión. Existen múltiples enfoques para su identificación y tratamiento:

II-B1. Identificación de valores atípicos:

- **Residuos estandarizados**: $z_i = \frac{e_i}{\sigma_e}$ donde σ_e es la desviación estándar de los residuos.
- **Rango intercuartílico**: Valores fuera de $[Q_1 - 1,5 \cdot IQR, Q_3 + 1,5 \cdot IQR]$ se consideran atípicos.

II-B2. Técnicas de tratamiento:

- **Eliminación**: Remover observaciones identificadas como atípicas.
- **Winsorización**: Reemplazar valores extremos por percentiles específicos (ej. percentil 5 y 95).
- **Transformaciones**: Aplicar funciones como logaritmo o raíz cuadrada para reducir la influencia de valores extremos.




Figura 2: Efecto de valores atípicos en un modelo de regresión lineal.

III. EVALUACIÓN Y VALIDACIÓN DE MODELOS

III-A. Partición de datasets

La división adecuada de los datos es crucial para evaluar la capacidad de generalización:

Cuadro I: Propósitos de los diferentes subconjuntos de datos

Subconjunto	Propósito
Entrenamiento	Ajuste de parámetros del modelo mediante optimización
Validación	Selección de hyperparámetros y monitorización del sobreajuste
Prueba	Evaluación final del rendimiento con datos nunca vistos

III-B. Técnicas de muestreo

- Muestreo aleatorio:** División randomizada que preserva la distribución original de los datos.
- Muestreo estratificado:** Mantiene la proporción de clases en cada partición, crucial para datos desbalanceados.
- Validación cruzada:** Divide los datos en k particiones y realiza k iteraciones de entrenamiento/validación.



Figura 3: Esquema de validación cruzada con $k = 5$ particiones.

Cuadro II: Características de modelos con sesgo o varianza elevados

Métrica	Alto sesgo	Alta varianza
Error entrenamiento	Alto	Bajo
Error validación	Alto	Alto
Comportamiento	Subajuste	Sobreajuste
Soluciones	Modelos más complejos	Regularización, más datos

IV. SESGO Y VARIANZA

IV-A. Diagnóstico de problemas comunes

IV-B. Estrategias de mejora

- Para alto sesgo:** Aumentar la complejidad del modelo, agregar características adicionales o reducir regularización.
- Para alta varianza:** Aumentar datos de entrenamiento, aplicar técnicas de regularización o reducir la complejidad del modelo.
- Compromiso óptimo:** Seleccionar la complejidad del modelo que minimice el error de generalización.




Figura 4: Relación entre complejidad del modelo y error de generalización.

V. CONCLUSIONES

La efectividad de los modelos de aprendizaje supervisado depende críticamente de la adecuada optimización de parámetros, el manejo de relaciones complejas entre variables, la identificación y tratamiento de valores atípicos, y la evaluación rigurosa mediante técnicas de validación apropiadas. El entendimiento del compromiso entre sesgo y varianza permite desarrollar modelos que generalizan efectivamente a nuevos datos, balanceando complejidad y capacidad predictiva.

REFERENCIAS

[1] Apuntes de la clase de Inteligencia Artificial, Profesor S. Pacheco, Instituto Tecnológico de Costa Rica, 2025.